

Karold Mejia

David Vergara

Informe de análisis de escalabilidad en procesamiento distribuido

Se evaluó el rendimiento del procesamiento distribuido de eventos GPS para tres volúmenes de datos distintos (1M, 10M y 100M de eventos), variando el número de nodos de procesamiento (workers). El objetivo fue determinar el impacto de la distribución de procesamiento en el tiempo total y la eficiencia por arco.

1. Resumen ejecutivo

Se procesaron archivos con 1M, 10M y 100M de eventos, utilizando entre 1 y 6 workers, donde se midió la duración total del procesamiento y se calculó el tiempo por arco, considerando el número total de arcos generados en cada archivo.

Para los archivos pequeños (1M), la escalabilidad es excelente: duplicar el número de workers reduce drásticamente el tiempo total. Para archivos medianos (10M), el beneficio de añadir más workers es menor, mostrando que el overhead de coordinación empieza a ser relevante. Mientras que para archivos grandes (100M), aumentar workers más allá de 4 reduce la eficiencia, indicando un punto donde distribuir más el procesamiento ya no es rentable.

Este análisis permite identificar el punto de corte: el número de workers a partir del cual aumentar nodos ya no mejora el rendimiento y puede incluso empeorarlo.


2. Resultados y métricas calculadas

Archivo	Workers	Arcos	Duración total (s)	Tiempo por arco (s)
datagrams_1M.csv	1	220	122.47	0.557
datagrams_1M.csv	2	220	12.41	0.056
datagrams_10M.csv	2	729	47.57	0.065
datagrams_10M.csv	4	729	40.08	0.055
datagrams_100M.csv	4	1063	226.69	0.213

datagrams_100M.csv	6	1063	288.37	0.271
--------------------	---	------	--------	-------


3. Análisis gráfico

Gráfico 1: Tiempo total vs número de workers



Podemos analizar que para 1M y 10M de datos, el aumento de número de workers reduce el tiempo total de procesamiento, mientras que para 100M, al usar 6 workers, el tiempo no se ve reducido sino aumentado.

Gráfico 2: Tiempo por arco vs Workers



Igualmente, se ve la mayor reducción en tiempo para 1M, y una reducción pequeña para 10M, mientras que para 100M el aumento de workers disminuyó su eficiencia.

4. Determinación del punto de corte

El punto de corte es el número de workers donde la eficiencia deja de mejorar o empeora. Con base a los gráficos, podemos analizar que para archivos de 1M y 10M: el tiempo sigue mejorando hasta el máximo de workers evaluados (2 y 4 respectivamente).

Por otro lado, para archivos de 100M: el punto de corte es 4 workers, ya que pasar a 6 incrementa la duración total y el tiempo por arco.

Con esto, se recomienda que para grandes volúmenes ($\geq 100\text{M}$ eventos), no es recomendable usar más de 4 workers en este entorno, ya que el overhead supera los beneficios.

6. Conclusión

Podemos concluir que el sistema escala muy bien con volúmenes pequeños y medianos, mostrando reducción casi lineal del tiempo total al aumentar los workers. Para volúmenes grandes, aumentar nodos más allá del punto de corte genera ineficiencia, evidenciado en el tiempo total y tiempo por arco.

Según los workers probados, tenemos que la cantidad óptima es 2 workers para 1M de eventos, 4 workers para 10M de eventos, y también 4 workers para 100M de eventos, ya que concluimos que 4 es el punto de corte para la cantidad correspondiente.