

Karold Mejia
David Vergara

Informe de análisis de escalabilidad en procesamiento distribuido

1. Resumen ejecutivo

Se analizó el rendimiento de procesamiento distribuido para tres volúmenes de datos (1M, 10M y 100M de eventos) utilizando distintos números de workers. Los hallazgos principales son:


- 1. Cargas grandes (10M y 100M): Presentan escalabilidad casi lineal al aumentar workers.
- 2. Carga pequeña (1M): Muestra un comportamiento anómalo con speedup extremo, sugiriendo mediciones atípicas que requieren verificación.
- 3. Distribución recomendada: Para volúmenes mayores a 10M, la distribución reduce significativamente el tiempo total con eficiencia superior al 94%.

2. Resultados y métricas calculadas

Dataset	Workers	Tiempo Total (s)	Speedup (vs. Baseline)	Eficiencia	Tiempo por 1M (s)
1M	1	2012.08	1.000	1.000	2012.080
1M	2	75.62	26.608	13.304	75.620
10M	2	791.60	1.000	1.000	79.160
10M	4	400.95	1.974	0.987	40.095
100M	4	4205.33	1.000	1.000	42.053
100M	8	2216.88	1.897	0.948	22.169


3. Análisis gráfico

Gráfico 1: Tiempo total vs número de workers



Podemos observar que las curvas para 10M y 100M muestran reducción consistente al incrementar workers, mientras que en el caso 1M presenta un outlier que distorsiona la tendencia esperada

Gráfico 2: Speedup vs Workers



Para 10M, tenemos un speedup de 1.97 (eficiencia 98.7%), mientras que para 100M el speedup es de 1.90 (eficiencia 94.8%). Por otro lado, para 1M, se presenta un speedup atípico de 26.6, probablemente debido a malas condiciones en la experimentación inicial.

4. Determinación del punto de corte

A partir de los resultados obtenidos, determinamos que para cargas grandes (10M y 100M), la eficiencia al distribuir es muy alta. Por lo tanto, distribuir desde 10M en adelante es claramente beneficioso cuando el objetivo es reducir el tiempo total. Para cargas pequeñas (1M), los datos son inconsistentes. En general, para 1M habitual no siempre compensa si el overhead de distribuir (setup, comunicación, serialización) es alto.

6. Conclusión

La distribución es efectiva para cargas mayores a 10M con eficiencia >94%, mientras que el overhead es aceptable principalmente para escalas grandes, ya que es crítico para datos pequeños.